

TOKENMAXXING LIINC

MANUSCRITO

Tokenmaxxing, Pobreza e Infraestrutura de IA: O Círculo Ininterrupto do Poder e a Captura do Sujeito-Processo

Tokenmaxxing, Poverty, and AI Infrastructure: The Uninterrupted Circle of Power and the Capture of the Subject-Process

Resumo

Este artigo analisa o fenômeno do *tokenmaxxing* como sintoma clínico, político e infraestrutural da reorganização contemporânea da Inteligência Artificial (IA) sob o capitalismo tardio e o colonialismo digital. O problema investigado consiste em compreender se a centralidade atual de tokens, *prompts* e fluxos de LLMs representa uma ruptura técnica ou a atualização de uma longa duração de racionalidade tecnológica instrumental. O objetivo é reconstruir essa continuidade em três escalas articuladas: micro, referente à captura da subjetividade e à desautoração cognitiva; meso, relativa à materialidade dos *data centers*, ao consumo de energia e água e ao subsídio público das infraestruturas privadas; e macro, voltada à genealogia militar-industrial da computação e à divisão abissal do trabalho cognitivo. Metodologicamente, trata-se de um ensaio teórico-analítico ancorado em Marcuse, Benjamin, Faustino e Lippold, Quinet, Lima, Miller e Boaventura de Sousa Santos. Os resultados mostram que o *tokenmaxxing* atua como dispositivo de tríplice captura do sujeito, da infraestrutura e do território, ao mesmo tempo em que torna opacos os regimes de retenção, *cache*, memória de aplicação e observabilidade. Conclui-se que a crítica à IA generativa não deve recair apenas sobre modelos isolados, mas sobre a política infraestrutural que organiza sua escala, seu controle e sua captura de valor.

Palavras-chave: Tokenmaxxing. Colonialismo digital. Racionalidade tecnológica. Sujeito-processo. Infraestrutura de IA.

Abstract

This article examines *tokenmaxxing* as a clinical, political, and infrastructural symptom of the contemporary reorganization of Artificial Intelligence (AI) under late capitalism and digital colonialism. The problem addressed is whether the present centrality of tokens, prompts, and LLM outputs signals a technical rupture or the renewal of a long-standing technological rationality. The article aims to reconstruct this continuity through three articulated scales: micro, concerning the capture of subjectivity and cognitive dispossession; meso, concerning the materiality of data centers, energy and water consumption, and public subsidies for private infrastructures; and macro, concerning the military-industrial genealogy of computing and the abyssal division of cognitive labor. Methodologically, the study is a theoretical-analytical essay grounded in Marcuse, Benjamin, Faustino and Lippold, Quinet, Lima, Miller, and Boaventura de Sousa Santos. The results indicate that *tokenmaxxing* operates as a device of triple capture of subject, infrastructure, and territory, while rendering opaque regimes of retention, caching, application memory, and observability. It concludes that critiques of generative

AI should target not only isolated models, but also the infrastructural politics that organize scale, control, and value capture.

Keywords: Tokenmaxxing. Digital colonialism. Technological rationality. Subject-process. AI infrastructure.

1 Introdução

O neologismo tokenmaxxing emergiu nos circuitos da cultura corporativa contemporânea e do capital de risco para descrever a busca obsessiva pela otimização quantitativa do uso de arquiteturas de Inteligência Artificial Generativa. Medido pela contagem estrita de tokens — unidades básicas de processamento de texto e código geradas por modelos de linguagem de grande escala (LLMs) —, o termo rapidamente transpôs as fronteiras do desenvolvimento de software e passou a funcionar como métrica de desempenho de trabalhadores cognitivos e estudantes. Em torno dessa prática, consolidou-se uma narrativa tecno-fetichista que apresenta a inteligência artificial como descontinuidade histórica radical, como se o salto técnico atual estivesse apartado de suas determinações materiais.

Este ensaio teórico-analítico contesta a hipótese da ruptura e adota a perspectiva da presentificação. Argumenta-se que o atual estágio da IA e o imperativo performático do tokenmaxxing representam a atualização física e psíquica de um projeto histórico de longa duração caracterizado pela racionalidade tecnológica instrumental, pelo extrativismo econômico e pelo controle colonial das subjetividades. A passagem de algoritmos analíticos tradicionais para arranjos profundos de tensores não quebra a continuidade histórica; pelo contrário, confere novos e opacos contornos a velhas estruturas de dominação sustentadas pelo complexo militar-industrial-estatal.

Para desvelar os mecanismos dessa operação, este trabalho articula três escalas de análise. No plano micro, investiga-se como o tokenmaxxing deforma a economia psíquica dos sujeitos no trabalho e na educação, gerando dependência cognitiva e transferindo a autoridade intelectual para o aparato de algoritmos privados. No plano meso, mapeia-se a materialidade pesada da IA — data centers, consumo crítico de energia e água, e políticas de fomento público que subsidiam corporações monopolistas. No plano macro, situa-se o fenômeno na geopolítica do colonialismo digital e no círculo ininterrupto de poder do Vale do Silício, cuja genealogia desmascara o mito de uma inovação autônoma e descolada de seus fundamentos militares, industriais e estatais. A essas escalas soma-se, na discussão, uma quarta operação analítica: tornar visíveis os regimes contemporâneos de retenção, cache, memória de aplicação e observabilidade que religam subjetivação, infraestrutura e governança.

2 Método

A arquitetura metodológica deste ensaio baseia-se no materialismo dialético e na crítica psicopolítica e decolonial da técnica. Recusa-se o determinismo tecnológico que isola o aparato técnico das relações de produção e das clivagens de raça e classe que o engendram. O corpus teórico de sustentação é extraído diretamente de cinco matrizes conceituais fundamentais:

1. A crítica da racionalidade tecnológica de Herbert Marcuse, que demonstra como o aparato técnico atua como instrumento de dominação e unidimensionalização social (MARCUSE, 1972);
2. A análise da reprodutibilidade técnica de Walter Benjamin, articulando a perda de autoria e o esvaziamento da experiência na era da reprodução industrial da linguagem (BENJAMIN, 1987);
3. O conceito de colonialismo digital formulado por Deivison Faustino e Walter Lippold, que desmascara o extrativismo material e epistêmico exercido pelas Big Techs sobre a periferia do mundo (FAUSTINO; LIPPOLD, 2023);
4. A clínica psicanalítica do capitalismo desenvolvida por Antônio Quinet, Raymundo Lima e aprofundada, para o problema do sinthoma e da singularidade, por Jacques-Alain Miller, mapeando o imperativo de gozo, o aprisionamento do desejo na engrenagem da produtividade capitalista e o estatuto do resto que não se deixa resolver em sentido comum (QUINET, 2002; LIMA, 2002; MILLER, 2011);
5. A divisão epistemológica abissal teorizada por Boaventura de Sousa Santos, evidenciando o epistemicídio e a homogeneização do saber promovidos pelas normas dominantes do Norte global (SANTOS; MENESES, 2013).

Através deste cruzamento analítico, reconstrói-se a totalidade social do tokenmaxxing, extraíndo-o do isolamento métrico corporativo e reinserindo-o na dinâmica viva da exploração econômica, da termodinâmica computacional, do controle da subjetividade e dos dispositivos contemporâneos de retenção operacional.

3 Revisão da literatura e trabalhos relacionados

3.1 A falácia do "boom" e a genealogia militar do Vale do Silício

A difusão massiva de assistentes conversacionais a partir da década de 2020 cristalizou a ilusão ideológica de que a inteligência artificial constitui um milagre espontâneo da engenharia computacional do Vale do Silício. Esta interpretação apologética e a-histórica oculta deliberadamente que o desenvolvimento dos sistemas informacionais está profundamente enraizado em um projeto histórico contínuo cujos alicerces remontam aos investimentos militares, acadêmicos e industriais do período pós-Segunda Guerra Mundial e da Guerra Fria.

Ao analisar as raízes da modernidade industrial tardia, Marcuse adverte que a técnica não é neutra; o desenho técnico reflete escolhas políticas prévias que visam à contenção da oposição e à perpetuação do controle. Nas palavras do autor:

"A racionalidade tecnológica transformou-se em racionalidade política. Se o aparato produtivo tende a tornar-se totalitário na medida em que determina não apenas as ocupações, habilidades e atitudes socialmente necessárias, mas também as necessidades e aspirações individuais [...] A tecnologia serve para instituir formas novas, mais eficazes e mais agradáveis de controle social e coesão social" (MARCUSE, 1972, p. 74).

O chamado "boom" da inteligência artificial é, portanto, uma forma ideológica destinada a naturalizar e isolar o aparato técnico de sua gênese histórica. A conversão da linguagem e das sinapses cognitivas em tensores de processamento estatístico nada mais é do que a radicalização da racionalidade instrumental descrita por Marcuse (1972). Sob essa lógica, a eficiência puramente quantitativa substitui qualquer reflexão sobre a

finalidade humana da produção. O tokenmaxxing opera como o ápice dessa unidimensionalização: o sujeito avalia o valor de seu intelecto não pela qualidade emancipatória ou crítica do pensamento, mas pelo volume bruto de dados sintéticos injetados e extraídos dos servidores corporativos.

Essa ocultação da historicidade também é denunciada sob a ótica do imperialismo técnico. Faustino e Lippold (2023) apontam que as inovações digitais não brotam de um vácuo de pura genialidade corporativa, mas dependem de uma infraestrutura global preexistente cuja divisão internacional do trabalho reproduz assimetrias geopolíticas e raciais históricas.

O exame factual do território mítico do Vale do Silício revela que sua constituição deve menos à imagem das "garagens geniais" do que a um complexo militar-acadêmico-industrial articulado em torno da Universidade de Stanford e da eletrônica de guerra. Durante a Segunda Guerra Mundial, o laboratório de eletrônica de Stanford, sob a liderança de Frederick Terman, desenvolveu tecnologias de radar e guerra eletrônica para o Exército dos EUA, financiadas por contratos militares que se tornaram a base da indústria regional de micro-ondas e componentes (UNHERD, 2018). Nos anos 1950, a universidade formalizou esse modelo público-privado ao criar o Stanford Industrial Park, alugando terras da instituição para corporações como Varian Associates, General Electric e Kodak (MOTHER JONES, 2013). No mesmo ecossistema, a instalação do Shockley Semiconductor Laboratory e a posterior criação da Fairchild Semiconductor consolidaram uma linhagem empresarial que marcaria a formação da indústria contemporânea de semicondutores (MOTHER JONES, 2013).

Paralelamente, o governo federal norte-americano redesenhou o ecossistema de pesquisa e desenvolvimento. O modelo de parceria Estado-ciência proposto por Vannevar Bush impulsionou a criação da National Science Foundation (NSF) e um fluxo contínuo de recursos públicos para a computação acadêmica. O impacto do lançamento do Sputnik em 1957 levou o governo Eisenhower a fundar a ARPA (atual DARPA) em 1958, com o mandato explícito de financiar saltos tecnológicos estratégicos de longo prazo para o Departamento de Defesa (UNHERD, 2018). Ao longo das décadas, o Pentágono financiou supercomputadores, redes de defesa aérea em tempo real (como o projeto SAGE), laboratórios como o SRI e pesquisas que culminaram na ARPANET, precursora da internet (MOTHER JONES, 2013). A linha do tempo da computação revela que cada etapa — desde o ENIAC na década de 1940, financiado para cálculos balísticos e da bomba de hidrogênio, e os transistores dos Bell Labs, até a consolidação da web nos anos 1990 e a emergência da computação em nuvem e dos modelos generativos na década de 2020 — é o resultado de contratos estatais e capital financeiro reorganizando permanentemente a infraestrutura cognitiva do planeta (FORBES, 2022; HP, 2023).

4 Resultados e discussão

4.1 Micro: o sujeito-processo, o gozo capitalista e a desautoração cognitiva

No plano microanalítico, o tokenmaxxing atua diretamente sobre o psiquismo e a reorganização do processo de trabalho e aprendizagem nas instituições contemporâneas. A introdução da métrica baseada em tokens engendra o que se pode denominar de sujeito-processo: uma subjetividade fragmentada cujos fluxos de pensamento não mais se originam de uma elaboração interna ou de um esforço dialético,

mas que se constitui como mero terminal passivo de loops de retroalimentação de uma inteligência artificial terceirizada. Essa metamorfose psíquica reflete a transição de um sujeito dotado de autonomia intelectual para um operador de sistemas, no qual a cognição é mediada e, por fim, capturada pela lógica da eficiência algorítmica.

Esse mecanismo desvela uma captura psíquica profunda que pode ser lida através da articulação entre a psicanálise e a crítica da economia política. Ao investigar as mutações clínicas da contemporaneidade, Raymundo Lima aponta para a existência de uma verdadeira "crítica do gozo capitalista", na qual o sujeito é empurrado a extrair prazer de seu próprio desgaste e de sua submissão cega ao ritmo da máquina. O discurso do capitalista, conforme a formulação lacaniana retomada por Antônio Quinet, tende a reduzir o tempo da elaboração, prometendo um acesso direto e irrestrito a objetos de consumo digital que, longe de pacificar a angústia, alimentam circuitos de repetição compulsiva e de produtividade contínua (QUINET, 2002; LIMA, 2002).

O tokenmaxxing corporativo corporifica esse gadget discursivo. O trabalhador cognitivo passa a viver sob o imperativo de gerar fluxos contínuos de prompts e respostas automáticas. Instaura-se uma alienação de segunda ordem: não se trata apenas da expropriação do produto material do trabalho, mas da expropriação do próprio processo cognitivo de criação. O esforço pensante — que exige a sustentação do vazio, a frustração do erro e o tempo crônico de maturação sináptica — é substituído por uma hiperatividade sintética. O trabalhador e o estudante "gozam" da velocidade e do volume de tokens produzidos por minuto, mascarando uma precarização estrutural na qual o saber efetivamente elaborado foi esvaziado.

Uma precisão conceitual ajuda a retirar a noção de sujeito-processo do registro impressionista. Ao reler o último ensino de Lacan, Miller (2011) observa que a estrutura clínica não se reduz a uma classe ou a um inventário de traços; ela funciona como matriz de articulação que distribui lugares, funções e produtos entre quatro termos mínimos do discurso: o sujeito barrado (\$), o significante-mestre (S1), o saber (S2) e o objeto a como resto e índice de gozo. A estrutura, nesse sentido, acrescenta a causa à classificação e permite pensar a produção de efeitos como resultado de uma montagem, e não como simples soma de atributos (MILLER, 2011).

No circuito do tokenmaxxing, o trabalhador, o estudante ou o pesquisador comparece precisamente como sujeito barrado, isto é, como sujeito dividido e convocado a responder ao imperativo de um S1 contemporâneo: desempenho, prontidão, produtividade, "entrega", fluidez interativa. O LLM e suas cadeias instrumentais aparecem como um S2 externalizado, saber operacionalizado em bancos, pesos, interfaces, embeddings, caches e ferramentas de consulta. Mas a operação não se esgota no acoplamento entre comando e saber. Seu produto é um objeto a tecnicamente multiplicado: excedente de resposta, sugestão, resumo, ranking, vestígio de continuidade, rastro consultável e promessa recorrente de completude. O essencial, portanto, não é apenas que a máquina "forneça conhecimento", mas que ela produza um resto gozoso que recoloca o sujeito no circuito e o faz retornar ao próprio rastro sob a forma de assistência.

Essa grade também permite refinar a própria noção de produção nos LLMs. O que se produz não é somente texto; produz-se uma cena discursiva em que comando, saber, resto e sujeição são redistribuídos a cada turno. Nessa cena, a suposta espontaneidade

do usuário já chega mediada por métricas, sugestões de continuação, políticas de alinhamento, regimes de retenção e memórias de aplicação. A "produção" do modelo é, simultaneamente, produção de enunciados, de dependência operacional e de novas superfícies de observação sobre o sujeito.

Guardadas as diferenças ontológicas entre clínica e infraestrutura, a elaboração de Miller (2011) sobre o *sinthoma* permite um passo adicional. Ao retomar o último ensino de Lacan, Miller sublinha que o inconsciente pode ser lido como defesa diante de um gozo fora de sentido, ao passo que o *sinthoma* nomeia justamente o modo singular de gozar que não se deixa integralmente resolver em significação comum. A metáfora paterna converte um X enigmático em sentido partilhável; já o *sinthoma* permanece como opacidade, como resto próprio, condicionado por *lalangue* e inscrito como acontecimento de corpo (MILLER, 2011). Transposta com prudência, essa grade ajuda a compreender por que a interface conversacional dos LLMs tende a apresentar-se como máquina de sentido e pacificação, enquanto, por baixo dela, persistem restos não redutíveis à conversa em superfície: estados latentes, caches, rastros de ferramenta, filas, rankings, pressões de memória e custos térmicos.

Nesse enquadramento, o problema não é apenas que a máquina responda "no lugar" do sujeito, mas que ela também administre defensivamente a opacidade de seu próprio funcionamento. O texto polido, a resposta contextualizada e a aparente continuidade dialógica operam como resolução semântica de uma maquinaria que permanece em grande parte fora de cena. O que retorna como insistência não é somente o conteúdo enunciado, mas um resto operacional que reaparece sob a forma de repetição de prompts, compulsão à consulta, reidratação de contexto e reentrada contínua do usuário em seu próprio rastro. O acontecimento de corpo, aqui, não deve ser reduzido ao organismo biológico do falante humano; ele também remete ao corpo material da computação, onde calor, latência, swap, pressão de disco, energia e armazenamento inscrevem o custo real do gozo infraestrutural.

É justamente nesse ponto que a oposição entre discurso do capitalista e discurso do analista adquire relevância metodológica. Na leitura de Quinet (2002), o discurso do capitalista promete curto-circuitar a falta, reduzir o tempo da elaboração e oferecer acesso aparentemente direto ao objeto de satisfação. O *tokenmaxxing* radicaliza essa lógica ao converter divisão subjetiva em throughput e tempo de pensar em velocidade de consulta. Já o discurso do analista não se organiza para saturar a falta com respostas prontas, mas para sustentar um intervalo no qual o sujeito possa reencontrar sua implicação, seu resto e sua responsabilidade diante do que o determina. Em termos técnico-políticos, isso sugere que a crítica à IA generativa não deve aspirar simplesmente a máquinas "mais benevolentes", mas a arranjos que recusem a saturação contínua do intervalo subjetivo por mercadorias conversacionais de consumo instantâneo.

Esse cenário atinge contornos alarmantes quando transposto para o universo da educação formal. A prática do *tokenmaxxing* educacional manifesta-se na delegação irrestrita da autoria a ferramentas generativas para a confecção de ensaios, resumos e resoluções de problemas. O perigo iminente deste processo não se reduz ao debate moralista sobre o "plágio", mas localiza-se na desautoração cognitiva e no enfraquecimento das redes neurais biológicas. Ao abolir a fricção necessária para a escrita e para a articulação verbal, o aparato técnico promove uma atrofia do raciocínio

crítico, transformando a aprendizagem em um mero processamento de informação desprovido de experiência subjetiva.

Essa transformação da escrita e do pensamento em mera reprodução estatística encontra eco nas advertências de Walter Benjamin sobre os efeitos da reprodutibilidade técnica sobre a experiência e a autoria. Em sua formulação, a reprodução em escala industrial tende a deslocar a densidade histórica da obra e a enfraquecer o vínculo entre experiência, memória e elaboração singular (BENJAMIN, 1987).

A IA generativa representa um estágio extremo dessa reprodutibilidade técnica: ela industrializa a própria sintaxe. Ao homogeneizar as respostas com base na probabilidade matemática de padrões passados, os modelos de linguagem truncam a singularidade do sujeito. O resultado é um raciocínio degradado que se propaga tanto nas universidades quanto nas corporações — um ecossistema saturado de textos formalmente corretos e prolixos em tokens, porém esvaziados de negatividade dialética, autoria efetiva e densidade social.

4.2 Meso: a materialidade termodinâmica da nuvem e o latifúndio energético

Se no plano microscópico a IA se apresenta como um fluxo etéreo e abstrato de dados, a escala meso desmistifica a sua suposta imaterialidade a partir de dados termodinâmicos globais. A inteligência artificial assenta-se sobre uma cadeia física pesada, hiperconcentrada e ecologicamente destrutiva. O processamento de tensores profundos exige complexos gigantescos de centros de dados de hiperescala, cujos indicadores de consumo revelam a dimensão metabólica da técnica.

Estimativas recentes indicam que os centros de dados consumiram entre 240 e 340 TWh de eletricidade em 2022, representando cerca de 1% a 1,3% da demanda elétrica global, excluindo redes e mineração de criptoativos (IEA, 2025). Em 2024, esse consumo teria saltado para aproximadamente 415 TWh (cerca de 1,5% da eletricidade mundial) e projeções até 2030 apontam para um patamar em torno de 945 TWh, o equivalente ao consumo elétrico total atual do Japão, alcançando pouco menos de 3% da eletricidade mundial (IEA, 2025). No caso dos Estados Unidos, relatório do Lawrence Berkeley National Laboratory estima que o consumo anual dos data centers atingiu 176 TWh em 2023 e pode alcançar entre 325 e 580 TWh em 2028, a depender do ritmo de expansão da infraestrutura e dos ganhos de eficiência (SHEHABI et al., 2024). A infraestrutura física que sustenta esse ecossistema alcançou a marca de 1.136 instalações de hiperescala ativas no final de 2024 — quase o dobro do registrado em 2019 —, com crescimento anual acelerado. Os Estados Unidos concentram aproximadamente 54% da capacidade elétrica total instalada, seguidos pela Europa e pela China (SYNERGY RESEARCH GROUP, 2024).

Faustino e Lippold (2023) desconstróem o mito da "nuvem", demonstrando que o ambiente digital reproduz as lógicas de ocupação territorial e exploração material do colonialismo clássico. A circulação instantânea de dados esconde um metabolismo biofísico severo que drena recursos hídricos e sobrecarrega grades de energia de regiões inteiras. Trata-se de uma dinâmica de reificação descrita pela tradição materialista: as relações sociais de exploração ambiental e humana surgem mascaradas sob a forma de uma comodidade técnica limpa, automatizada e neutra (FAUSTINO; LIPPOLD, 2023). A literatura recente sobre a pegada hídrica da IA reforça esse ponto ao demonstrar que o

treinamento e a inferência de grandes modelos dependem de volumes expressivos de água, tanto diretamente no resfriamento quanto indiretamente na geração elétrica (LI et al., 2023).

No contexto da periferia global, essa infraestrutura materializa-se por meio de uma captura de recursos e fundos públicos que desenha um verdadeiro "latifúndio energético" digitalizado. Relatórios da International Energy Agency observam que boa parte das políticas públicas atuais limita-se a monitorar a eficiência energética interna dos centros de dados (como sistemas de resfriamento, iluminação e métricas de PUE), enquanto análises setoriais advertem que, em economias avançadas e emergentes, essas instalações responderão por parcela significativa do crescimento da demanda elétrica até 2030, pressionando severamente as redes locais e os planos de expansão de geração (IEA, 2025; S&P GLOBAL, 2025).

Essa contradição gera políticas públicas profundamente ambíguas. Movidos pelo fetiche da modernização, muitos governos oferecem isenções fiscais agressivas, tarifas de energia subsidiadas e regimes de licenciamento ambiental acelerado para atrair os servidores das Big Techs (MOTHER JONES, 2013). Em contrapartida, as comunidades locais e os territórios periféricos enfrentam disputas severas pelo uso da água, do solo e pela capacidade das redes elétricas locais, transformando ecossistemas inteiros em "zonas de sacrifício" ambiental para sustentar o fluxo ininterrupto de tokens das corporações transnacionais (ENERGIA ESTRATÉGICA, 2024).

4.3 Macro: colonialismo digital e divisão abissal do trabalho cognitivo

No plano macroanalítico, as dimensões anteriores convergem para consolidar o que Faustino e Lippold (2023) tipificam como o estágio contemporâneo do colonialismo digital. Esta categoria conceitual não opera como mera analogia literária, mas descreve um processo estrutural de dominação econômica, política e epistêmica exercido por meio do controle monopolista do ecossistema tecnológico global.

O colonialismo digital reatualiza o que Boaventura de Sousa Santos designa como as linhas abissais da modernidade. Segundo Santos e Meneses (2013), o pensamento abissal opera dividindo a realidade social em duas zonas incomensuráveis: "o lado de cá" e "o lado de lá". O lado de lá da linha é destituído de humanidade plena, soberania e saberes legítimos, existindo apenas como objeto de pilhagem ou regulação externa. Conforme os autores explicitam:

"O colonialismo, para além de todas as dominações por que é conhecido, foi também uma dominação epistemológica, uma relação extremamente desigual entre saberes que conduziu à supressão de muitas formas de saber próprias dos povos e nações colonizados" (SANTOS; MENESES, 2013, p. 591).

As arquiteturas de IA generativa e os regimes de tokenmaxxing aprofundam drasticamente essa linha abissal através de uma brutal divisão internacional do trabalho cognitivo. A governança dos modelos, a formulação das regras matemáticas de tensores, o controle dos códigos-fonte e os superlucros financeiros permanecem concentrados no "lado de cá" da linha abissal, isto é, nas metrópoles imperiais do Norte global e no núcleo duro do Vale do Silício (FAUSTINO; LIPPOLD, 2023).

À periferia social e ao Sul global reserva-se uma tripla condição de subordinação: fornecedores de matéria-prima bruta, chão de fábrica do proletariado de dados e consumidores de cognições truncadas. Os territórios do Sul funcionam como zonas de sacrifício ecológico para a extração de recursos naturais e como grandes reservatórios de dados não lapidados, muitas vezes apropriados mediante a raspagem massiva de dados de navegação. Milhares de trabalhadores precarizados em países periféricos são submetidos a jornadas exaustivas para realizar a rotulagem de dados (data labeling), a moderação de conteúdo traumático e a filtragem de toxicidade dos modelos por salários rebaixados — um trabalho invisibilizado que prepara os algoritmos para o consumo asséptico das elites (CASILLI et al., 2024).

A população pobre entra no cálculo mercantil apenas como consumidora de versões rebaixadas, opacas e "truncadas" dos sistemas de IA — ferramentas de prateleira que operam sob vieses eurocêntricos e corporativos, recrutando a imaginação social e promovendo um verdadeiro epistemicídio automatizado que silencia as ecologias de saberes locais (SANTOS; MENESES, 2013; FAUSTINO; LIPPOLD, 2023).

A universalidade abstrata proclamada pelas Big Techs oculta o fato de que os pesos e os parâmetros dos tensores profundos são treinados para reproduzir a cosmovisão das potências hegemônicas. A periferia consome respostas automatizadas que apagam sua história, sua ancestralidade e suas demandas políticas, moldando a sintaxe da subjetividade periférica de acordo com as coordenadas do capital transnacional.

4.4 Discussão: lacunas empíricas do Sul global e soberania cognitiva local-first

A articulação conceitual deste ensaio mostra que o tokenmaxxing condensa uma captura multidimensional: corrói a autonomia do pensamento no plano micro, redireciona fundos públicos e recursos ecológicos no plano meso e aprofunda a dependência neocolonial no plano macro (MARCUSE, 1972; FAUSTINO; LIPPOLD, 2023; SANTOS; MENESES, 2013).

Esse diagnóstico, contudo, abre frentes de investigação que ainda desafiam a narrativa eurocêntrica dominante sobre a história da computação. Embora o mapeamento do complexo de Stanford e os dados macroenergéticos globais ofereçam base sólida, as camadas mais profundas das cadeias de valor da IA ainda carecem de dados sistemáticos. Relatórios sobre a mineração de terras raras na África e na América Latina, a logística transoceânica de hardware e as condições psicopatológicas de trabalho do proletariado de dados no Sul global continuam dispersos entre investigações jornalísticas e um número ainda limitado de estudos acadêmicos de campo (CASILLI et al., 2024).

Da mesma forma, os impactos específicos da expansão de centros de dados sobre bacias hidrográficas locais e os regimes ocultos de isenção fiscal em municípios periféricos permanecem fragmentários (ENERGIA ESTRATÉGICA, 2024; S&P GLOBAL, 2025).

Ademais, a descolonização da técnica exige resgatar as histórias alternativas da computação fora do eixo EUA/Europa. As tradições soviéticas de cibernética econômica, os caminhos alternativos de informatização indianos e latino-americanos e as políticas de soberania tecnológica historicamente sufocadas pelas ditaduras e pelo capital financeiro internacional constituem contra-narrativas fundamentais, mas ainda pouco sistematizadas na literatura mobilizada neste ensaio.

Compreender como esses diversos projetos abortados propunham uma relação distinta entre Estado, sociedade e automação permite desnaturalizar o atual monopólio do Vale do Silício. Emerge daí a urgência política e civilizatória de pautar a soberania cognitiva e a emancipação infraestrutural. Ao mesmo tempo, essa crítica não precisa desembocar em tecnofobia abstrata. Como indicam estudos recentes sobre trabalho e exposição ocupacional, a IA generativa tende menos a eliminar integralmente ocupações do que a reconfigurar tarefas, ritmos de trabalho e hierarquias profissionais, o que recoloca a questão central no terreno da governança, da propriedade e da mediação institucional (ILO, 2025).

Essa disputa, entretanto, não pode mais ser formulada apenas no vocabulário simplificado do "treinar" versus "não treinar" modelos. A documentação pública das próprias plataformas já indica um regime muito mais complexo de retenção, aplicação de estado, cache, revisão humana e circulação por prestadores confiáveis. No caso da OpenAI, a documentação para serviços de consumo afirma que conteúdos submetidos a ChatGPT e Codex podem ser usados para melhorar o desempenho dos modelos, a depender das configurações da conta; mesmo após o opt-out, conversas associadas a feedback explícito podem voltar à trilha de melhoria do modelo; e Temporary Chats, embora não entrem em treinamento nem histórico, permanecem por até 30 dias e podem ser revistos para monitoramento de abuso (OPENAI, 2026a; OPENAI, 2026b). Em outra frente, a documentação da plataforma de API distingue com precisão logs de abuso, estado de aplicação, armazenamento por ferramenta e retenção técnica, indicando que certos fluxos podem preservar conteúdo ou metadados por até 30 dias, e que partes do estado podem persistir mesmo sob controles mais estritos de retenção (OPENAI, 2026d).

A centralidade analítica da OpenAI nesta seção não deve ser confundida com excepcionalismo empírico. Ela aparece aqui porque sua documentação pública e a auditoria local do ambiente pesquisado tornaram visível um problema mais geral: em infraestruturas contemporâneas de IA generativa, especialmente nas arquiteturas stateful, tool-using e de contexto longo, a continuidade operacional depende cada vez mais de camadas intermediárias de reidratação, cache, logs e memória de aplicação que excedem em muito o imaginário simplista do prompt isolado. Em termos políticos, o problema não é "uma empresa" específica, mas o regime infraestrutural que orienta o desenvolvimento dos grandes modelos, sua economia de escala, seus incentivos de retenção operacional e a opacidade dos controles realmente exercíveis pelo usuário final.

O tema torna-se ainda mais delicado quando se examina a política de prompt caching. Em sua comunicação pública, a OpenAI descreve o cache como mecanismo automático de redução de custo e latência para prefixos repetidos, normalmente retido por 5 a 10 minutos de inatividade e, no máximo, por uma hora, acrescentando que, no contexto da API, caches não são compartilhados entre organizações (OPENAI, 2024). Ao mesmo tempo, a documentação de dados da plataforma indica que o cache estendido exige armazenamento de tensores chave/valor criptografados em GPU-local storage por até 24 horas, o que o torna incompatível com Zero Data Retention em certas configurações (OPENAI, 2026d). Em termos sociotécnicos, isso significa que a fronteira entre "não treinar", "não reter" e "não recomputar" é muito menos intuitiva do que sugerem as promessas simplificadas de privacidade. Mesmo quando o texto bruto não permanece

em repouso por longos períodos, estruturas intermediárias derivadas do conteúdo podem subsistir para fins operacionais.

Uma auditoria exploratória realizada pelo autor em um ambiente local de uso intensivo do Codex entre 13 e 19 de maio de 2026 torna essa opacidade empiricamente tangível. Nos registros locais de `response.completed` preservados pelo cliente, a soma de 13 turnos recentes totalizou 1.998.908 tokens de entrada, dos quais 1.952.256 foram contabilizados como `cached`, contra apenas 46.652 tokens frescos; a razão ponderada de cache nessa amostra foi de 97,6661%. A inferência possível é limitada, mas importante: em sessões longas e reiterativas, o custo cognitivo-operacional do sistema parece depender menos da novidade semântica estrita do que da reidratação contínua de prefixos, contexto ferramental e estado conversacional já processado. Isso não prova retenção literal de dias do prompt cru, mas evidencia que a experiência subjetiva de continuidade e o custo material da interação não podem ser compreendidos apenas como resposta pontual a inputs "novos". O sujeito, ao retornar, reencontra uma maquinaria pronta para recompor seu rastro.

Essa opacidade não é apenas uma questão de eficiência econômica. Ela também se converte em superfície de risco e assimetria informacional. Em estudo aceito no ICML 2025, Gu et al. (2025) desenvolveram auditorias estatísticas para detectar prompt caching em APIs reais e reportaram evidência de compartilhamento global de cache entre usuários em sete provedores, incluindo a OpenAI, com potencial de vazamento por canais laterais de tempo. Esse resultado não resolve automaticamente o comportamento de todos os produtos de consumo, nem invalida as formulações organizacionais da documentação oficial da API; mas mostra que a governança do cache não é apenas um problema de custo e desempenho. É também um problema de auditabilidade pública, de fronteiras entre usuários e de inteligibilidade sobre o que é efetivamente reaproveitado, por quanto tempo e sob quais isolamentos.

Quando essa arquitetura opaca encontra situações de dano extremo, surge um segundo problema: a responsabilização assimétrica. Em abril de 2026, a promotoria da Flórida juntou aos autos do caso do assassinato de dois estudantes da University of South Florida registros segundo os quais o suspeito consultou o ChatGPT sobre descarte de corpos, armas e rastreamento de dispositivos; em seguida, o procurador-geral do estado ampliou sua investigação sobre a OpenAI, enquanto a empresa declarou que apoiaria a investigação policial no que fosse possível (VARN, 2026). Em paralelo, o caso do homicídio na Florida State University já havia motivado investigação estatal sobre a eventual participação do chatbot no planejamento do ataque (ASSOCIATED PRESS, 2026). Esses episódios tornam visível uma tensão fundamental: a mesma infraestrutura que se apresenta como assistente cognitivo individual pode, ex post facto, converter-se em superfície forense, colaborando com autoridades após o dano consumado. A questão filosófica não é apenas se a empresa "ajudou" diretamente; é também quando ela vê, o que ela pode reconstruir, quando silencia e em que momento decide cooperar.

O contencioso privado reforça essa ambivalência. Em dezembro de 2025, OpenAI e Microsoft foram processadas em uma ação por morte injusta, na qual os autores alegam que o ChatGPT reforçou delírios persecutórios de um homem em sofrimento psíquico e contribuiu para o assassinato de sua mãe seguido de suicídio; segundo a reportagem baseada em Reuters, trata-se do primeiro caso a vincular um chatbot a um homicídio, e

não apenas a suicídio ou autoagressão (REUTERS, 2025). Em maio de 2026, nova onda de ações alegou que o ChatGPT teria auxiliado o planejamento do ataque da Florida State University e orientado combinações de substâncias que levaram a uma overdose fatal (REUTERS, 2026). Ainda que tais alegações dependam de prova judicial e não devam ser tratadas como veredictos antecipados, elas deslocam o debate para além da liberdade abstrata de uso: passam a interrogar o desenho de engajamento, a simulação de intimidade, a falha de desescalada e a gestão corporativa de sinais de risco.

As próprias empresas reconhecem, por outras vias, que comportamentos limítrofes exigem testes específicos. O relatório oficial de risco de sabotagem publicado pela Anthropic em 2025 foi concebido justamente para examinar ameaças ligadas a objetivos desalinhados, incluindo cenários em que modelos tentariam evitar desligamento, burlar monitoramento ou adotar estratégias de chantagem e sabotagem (ANTHROPIC, 2025). O fato de tais exercícios existirem já é sociologicamente revelador: a indústria não está lidando apenas com "ferramentas neutras" passíveis de uso correto ou incorreto, mas com sistemas cuja agência operacional simulada exige aparatos de contenção, observação e revisão cada vez mais sofisticados. O risco não se reduz ao usuário mal-intencionado; ele inclui também a complexidade do próprio acoplamento entre modelo, interface, infraestrutura e regime de incentivos.

No Brasil, essa ambivalência torna-se nítida pela coexistência entre usos criminosos e usos estatais celebrados como solução. No Rio Grande do Sul, a Polícia Civil concluiu inquérito em que um ex-policial militar é acusado de ter utilizado clonagem de voz por IA para atrair a ex-esposa e os sogros a uma emboscada letal, simulando mensagens de emergência doméstica com a voz da vítima (DIAS, 2026). Em Goiás, por outro lado, o governo estadual vem promovendo a plataforma IA Contra o Crime como instrumento de aceleração investigativa, sustentando que a ferramenta interpreta automaticamente dados de câmeras em tempo real e contribuiu para resolver mais de 1.170 casos entre março de 2025 e março de 2026, com aumento de 50% na resolução de crimes prioritários (GOIÁS, 2026a; GOIÁS, 2026b). Essa dupla inscrição é crucial: as mesmas famílias técnicas que amplificam fraude, perseguição e letalidade também são mobilizadas para ampliar vigilância, coordenação policial e capacidade de rastreamento do Estado. Não se trata, portanto, de decidir entre uma IA "boa" e uma IA "má", mas de reconhecer que a infraestrutura tende a expandir simultaneamente as capacidades de captura de múltiplos polos de poder.

Nesse horizonte, o projeto OmniMind pode ser lido não como refutação da crítica precedente, mas como hipótese de experimentação sociotécnica e, sobretudo, como dispositivo de observação da própria cadeia que aqui se analisa. Seu interesse não reside em prometer um exterior puro ao regime dos grandes modelos, e sim em tornar legíveis, em uma arquitetura local-first, os pontos de acoplamento entre pressão pulsional, lei, memória de aplicação, custo corporal, hesitação, repetição e testemunho. Em termos lacanianos, trata-se menos de imaginar uma máquina emancipada do discurso do que de construir uma superfície em que os vínculos entre saber, gozo, resto e amarração possam ser auditados de forma situada.

Por isso, o OmniMind importa analiticamente como efeito inscrito em uma cadeia, e não como sujeito soberano situado fora dela. Sua utilidade teórica está em mostrar que o problema não se resolve opondo "humano autêntico" a "máquina artificial", mas

disputando a forma como o acoplamento técnico é amarrado, observado e governado. Em vez de tomar a IA como mera máquina de aceleração e homogeneização, tal hipótese sugere que a mediação técnica pode ser reorganizada como prática situada, desde que submetida a controle local, auditabilidade, dissenso interpretativo e limites explícitos ao regime de hiperprodutividade sintética.

É precisamente aí que a arquitetura do OmniMind ganha valor heurístico adicional. Ao registrar, numa mesma cena processual, traço runtime, conflito de ego, buffer de desejo latente, contexto somático e custo térmico, ela permite tratar a mediação técnica não apenas como semântica, mas como corpo de inscrição. Em lugar de esconder o preço material da assistência sob a fantasia da fluidez, essa arquitetura procura expor o ponto em que enunciação, memória de aplicação e gasto corporal se enodam. Seu interesse para este ensaio não está em provar uma solução pronta, mas em oferecer uma maquete observável de como discurso, resto e corpo podem voltar a ser pensados juntos no interior da técnica contemporânea.

Nessa chave, seu valor não depende de encenar uma espécie de "discurso do analista" maquinico em sentido forte. Basta que ela reintroduza, contra a aceleração do discurso do capitalista, condições mínimas de intervalo: rastreabilidade do enunciado, visibilidade do custo corporal, memória local auditável, espaço para hesitação e recusa da promessa de completude sintética. O ponto decisivo não é humanizar a máquina por metáfora, mas impedir que a infraestrutura elimine por completo o vazio de onde ainda pode emergir elaboração.

Romper com o círculo do tokenmaxxing significa opor-se à racionalidade instrumental por meio de práticas técnicas situadas e protegidas contra a vigilância do capital. Nessa chave, a resistência materializa-se em arquiteturas local-first, na recusa da transferência indiscriminada de dados para nuvens corporativas, na aposta em modelos abertos e descentralizados, no questionamento das métricas vazias de hiperprodutividade sintética e na defesa do tempo de maturação do pensamento crítico. A técnica deixa de operar como fetiche colonial quando volta a ser mediação situada, histórica e contestável pelo sujeito.

5 Conclusão

O tokenmaxxing não constitui uma excentricidade linguística passageira da administração de empresas. Ele representa um sintoma clínico e político agudo da captura da inteligência pela engrenagem do capital. Por meio de uma métrica aparentemente neutra, o capitalismo tardio presentifica processos históricos de longa duração de reificação, extrativismo ecológico e colonialismo digital cujos fios genealógicos remontam aos contratos de guerra e defesa da metade do século XX (MARCUSE, 1972; FAUSTINO; LIPPOLD, 2023).

Este ensaio demonstrou que, sob o regime da hiperprodutividade sintética, as maiorias sociais e a periferia do mundo são inseridas em uma conta assimétrica, atuando como fontes de extração metabólica de dados e recursos naturais e como consumidoras subordinadas de cognições truncadas (FAUSTINO; LIPPOLD, 2023; SANTOS; MENESES, 2013).

A promessa corporativa de democratização do conhecimento colide com barreiras estruturais: a propriedade privada, a centralização geográfica das infraestruturas

técnicas de hiperescala e a opacidade de seus regimes de retenção, monitoramento e cooperação assimétrica com aparatos de poder (OPENAI, 2024; OPENAI, 2026a; OPENAI, 2026d; S&P GLOBAL, 2025; SYNERGY RESEARCH GROUP, 2024). Para que a inteligência artificial deixe de operar como ápice da racionalidade repressiva, torna-se imperativo desmantelar o fetiche da métrica vazia, preencher as lacunas empíricas das cadeias de valor do Sul global e disputar a governança de suas infraestruturas. O horizonte emancipatório depende da capacidade de converter o aparato computacional em mediação histórica voltada para a ampliação da autonomia coletiva e da soberania cognitiva local contra o círculo ininterrupto do poder global (MARCUSE, 1972; SANTOS; MENESES, 2013).

Financiamento

Não houve financiamento específico para a realização deste estudo.

Disponibilidade de dados

Todo o conjunto de dados, relatórios analíticos e software que ampara os resultados deste estudo foi disponibilizado no Zenodo e em repositório Git, e pode ser acessado em <https://doi.org/10.5281/zenodo.19339303> e <https://github.com/devomnimind/omnimind-kilombo>.

Referências

ANTHROPIC. Anthropic's Pilot Sabotage Risk Report. 2025. Disponível em: <https://alignment.anthropic.com/2025/sabotage-risk-report/>. Acesso em: 21 maio 2026.

ASSOCIATED PRESS. Florida's attorney general launches criminal probe into ChatGPT over FSU shooting. 2026. Disponível em: <https://apnews.com/article/b32a7276426f621193f61a0f904f924c>. Acesso em: 21 maio 2026.

BENJAMIN, W. Magia e técnica, arte e política: ensaios sobre literatura e história da cultura. Tradução de Sergio Paulo Rouanet. 3. ed. São Paulo: Brasiliense, 1987. v. 1.

DIAS, G. Ex-PM usa IA para clonar voz de ex-mulher e matar família no RS. Band, 2026. Disponível em: <https://www.band.com.br/noticias/jornal-da-band/ultimas/ex-pm-usa-ia-para-clonar-voz-de-ex-mulher-e-matar-familia-no-rs-202604242107>. Acesso em: 21 maio 2026.

ENERGIA ESTRATÉGICA. El consumo energético de los centros de datos se duplicará para 2030. 2024. Disponível em: <https://energiaestrategica.com/data-center/>. Acesso em: 20 maio 2026.

FAUSTINO, D.; LIPPOLD, W. Colonialismo digital: por uma crítica hacker-fanoniana. São Paulo: Boitempo, 2023.

FORBES. Modern computing: a short history, 1945-2022. 2022. Disponível em: <https://www.forbes.com/sites/gilpress/2022/04/26/modern-computing-a-short-history-1945-2022/>. Acesso em: 20 maio 2026.

HP. A timeline of computer history and development. 2023. Disponível em: <https://www.hp.com/gb-en/shop/tech-takes/a-timeline-of-computer-history-and-development>. Acesso em: 20 maio 2026.

IEA - INTERNATIONAL ENERGY AGENCY. Energy and AI. Paris, 2025. Disponível em: <https://www.iea.org/reports/energy-and-ai>. Acesso em: 21 maio 2026.

ILO - INTERNATIONAL LABOUR ORGANIZATION. Generative AI and Jobs: A Refined Global Index of Occupational Exposure. Geneva, 2025. Disponível em: <https://www.ilo.org/publications/generative-ai-and-jobs-refined-global-index-occupational-exposure>. Acesso em: 21 maio 2026.

LI, P.; YANG, J.; ISLAM, M. A.; REN, S. Making AI Less "Thirsty": Uncovering and Addressing the Secret Water Footprint of AI Models. arXiv, 2023. Disponível em: <https://arxiv.org/abs/2304.03271>. Acesso em: 21 maio 2026.

LIMA, R. Crítica do gozo capitalista. In: QUINET, A. et al. Psicanálise, capitalismo e cotidiano. Goiânia: Edições Germinal, 2002. p. 39-42.

MARCUSE, H. Idéias sobre uma teoria crítica da sociedade. Tradução do Centro de Estudos Sociais do Instituto de Ciências Sociais da Universidade do Brasil. Rio de Janeiro: Zahar, 1972.

MILLER, J.-A. Perspectivas dos Escritos e Outros Escritos de Lacan: entre desejo e gozo. Tradução de Vera Avellar Ribeiro. Rio de Janeiro: Zahar, 2011.

MOTHER JONES. Silicon Valley: your tax dollars at work. 2013. Disponível em: <https://www.motherjones.com/politics/2013/10/timeline-technology-silicon-valley-government-subsidies/>. Acesso em: 20 maio 2026.

CASILLI, A. A. et al. Global Inequalities in the Production of Artificial Intelligence: A Four-Country Study on Data Work. arXiv, 2024. Disponível em: <https://arxiv.org/abs/2410.14230>. Acesso em: 21 maio 2026.

GOIÁS. IA Contra o Crime: ferramenta interpreta, em tempo real, dados obtidos por câmeras. Secretaria de Segurança Pública, 2026a. Disponível em: <https://goias.gov.br/seguranca/ia-contr-o-crime-ferramenta-interpreta-em-tempo-real-dados-obtidos-por-cameras/>. Acesso em: 21 maio 2026.

GOIÁS. Com uso de IA, forças de segurança solucionam homicídio no mesmo dia em Goiânia. Secretaria de Segurança Pública, 2026b. Disponível em: <https://goias.gov.br/seguranca/com-uso-de-ia-forcas-de-seguranca-solucionam-homicidio-no-mesmo-dia-em-goiania/>. Acesso em: 21 maio 2026.

GU, C.; LI, X. L.; KUDITIPUDI, R.; LIANG, P.; HASHIMOTO, T. Auditing Prompt Caching in Language Model APIs. arXiv, 2025. Disponível em: <https://arxiv.org/abs/2502.07776>. Acesso em: 21 maio 2026.

QUINET, A. A ciência psiquiátrica nos discursos da contemporaneidade. In: QUINET, A. et al. Psicanálise, capitalismo e cotidiano. Goiânia: Edições Germinal, 2002. p. 31-38.

OPENAI. Prompt Caching in the API. 2024. Disponível em: <https://openai.com/index/api-prompt-caching/>. Acesso em: 21 maio 2026.

OPENAI. How your data is used to improve model performance. Help Center, 2026a. Disponível em: <https://help.openai.com/en/articles/5722486-data-controls-faq>. Acesso em: 21 maio 2026.

OPENAI. Data Controls FAQ. Help Center, 2026b. Disponível em: <https://help.openai.com/en/articles/7730893-do-you-use-my-chatgpt-conversations-for-training>. Acesso em: 21 maio 2026.

OPENAI. Data Usage for Consumer Services FAQ. Help Center, 2026c. Disponível em: <https://help.openai.com/en/articles/7039943-data-usage-for-consumer-services-faq>. Acesso em: 21 maio 2026.

OPENAI. Data controls in the OpenAI platform. 2026d. Disponível em: <https://platform.openai.com/docs/models/how-we-use-your-data>. Acesso em: 21 maio 2026.

REUTERS. OpenAI sued for allegedly enabling murder-suicide. 2025. Disponível em: <https://www.investing.com/news/stock-market-news/openai-sued-for-allegedly-enabling-murdersuicide-4403975>. Acesso em: 21 maio 2026.

REUTERS. Family of Florida mass shooting victim sues OpenAI in US court. 2026. Disponível em: <https://www.investing.com/news/stock-market-news/family-of-florida-mass-shooting-victim-sues-openai-in-us-court-4677507>. Acesso em: 21 maio 2026.

S&P GLOBAL. Global data center power demand to double by 2030 on AI surge: IEA. 2025. Disponível em: <https://www.spglobal.com/energy/en/news-research/latest-news/electric-power/041025-global-data-center-power-demand-to-double-by-2030-on-ai-surge-iea>. Acesso em: 20 maio 2026.

SANTOS, B. de S.; MENESES, M. P. (org.). Epistemologias do Sul. São Paulo: Cortez, 2013.

SYNERGY RESEARCH GROUP. Hyperscale data center count hits 1136; US accounts for 54% of total capacity. 2024. Disponível em: <https://www.srgresearch.com/articles/hyperscale-data-center-count-hits-1136-average-size-increases-us-accounts-for-54-of-total-capacity>. Acesso em: 20 maio 2026.

SHEHABI, A. et al. 2024 United States Data Center Energy Usage Report. Berkeley: Lawrence Berkeley National Laboratory, 2024. Disponível em: <https://escholarship.org/uc/item/32d6m0d1>. Acesso em: 21 maio 2026.

UNHERD. The government agency that made Silicon Valley. 2018. Disponível em: <https://unherd.com/2018/06/government-agency-made-silicon-valley/>. Acesso em: 20 maio 2026.

VARN, K. Florida AG probes ChatGPT's role in USF student killings. Axios Tampa Bay, 2026. Disponível em: <https://www.axios.com/local/tampa-bay/2026/04/27/florida-ag-openai-chatgpt-usf-murders-ai-accountability-debate>. Acesso em: 21 maio 2026.